

DADOS, PYTHON E ESTATÍSTICA: CAMINHOS PARA STEM

Ana Júlia Amaro Pereira Rocha

SEMANA 2
DIA 4

O QUANTO OS DADOS VARIAM

Como já comentei anteriormente, a **média nem sempre resume bem o conjunto de dados**. Duas turmas podem ter a mesma média de notas, por exemplo, mas serem bem diferentes. Uma pode ter notas muito parecidas entre si e a outra pode ter notas muito altas e muito baixas.

Por isso, precisamos das **medidas de dispersão**. Porque elas mostram o quanto espalhados os dados estão em relação ao valor central. Vamos focar em duas medidas principais: **variância e desvio padrão**.

MEDIDAS DE DISPERSÃO

Variância: mede o quanto, em média, os valores se afastam da média.
Quanto maior a variância, “mais diferentes são os valores entre si”.

Para População (σ^2):

$$\sigma^2 = \frac{\sum_{i=1}^N (x_i - \mu)^2}{N}$$

- x_i : cada valor do conjunto de dados.
- μ : média populacional.
- N : número total de elementos na população.

Para Amostra (s^2):

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}$$

- x_i : cada valor da amostra.
- \bar{x} : média amostral.
- n : número total de elementos na amostra.

MEDIDAS DE DISPERSÃO

Desvio Padrão: indica, aproximadamente, quanto os dados costumam variar em relação à média. É uma forma mais intuitiva de ver a variância.

Um desvio padrão pequeno indica dados mais consistentes.


Um desvio padrão grande indica dados mais irregulares.

$$\sigma = \sqrt{\sigma^2} \quad \text{ou} \quad s = \sqrt{s^2}$$

OUTLIERS



Como já comentei em sala, os **outliers** são valores muito distantes do restante dos dados, podendo acontecer por erros de digitação, erro de coleta ou em situações reais, mas raras.

O “problema” deles é que **podem distorcer médias e análises**. Então, precisamos investigá-los e, assim, até podemos apagá-los em alguns casos.



BOXPLOT

É um gráfico que mostra mediana, quartis, dispersão e possíveis outliers. O boxplot ajuda a visualizar rapidamente como os dados estão distribuídos.



CORRELAÇÃO VS CAUSALIDADE


Correlação indica que duas variáveis mudam juntas, podendo acontecer de forma positiva quando ambas aumentam ou de forma negativa quando uma aumenta e a outra diminui. Mas, **correlação não implica causalidade**.

Duas coisas podem ser relacionadas sem que uma cause a outra. Às vezes, existe uma terceira variável “escondida” ou é apenas uma coincidência.

Um exemplo clássico é a relação entre vendas de sorvete e ataques de tubarão. Ambos aumentam no verão, mas sorvete não causa ataques, a terceira variável (calor/verão) causa ambos, levando mais pessoas a tomar sorvete e ir ao mar.

COEFICIENTE DE PEARSON

O coeficiente de correlação de Pearson mede o grau de relação linear entre duas variáveis numéricas, variando de -1 (**relação negativa forte**), 0 (**sem relação**) e 1 (**relação positiva forte**).
Não prova causalidade, apenas indica associação.



ESTUDO DE CASO

A seguir temos 10 situações as quais vamos analisar juntos quando se trata de correlação e quando é causalidade.

1 - Vendas de sorvete e casos de insolação aumentam no verão.

Correlação. O calor influencia em ambos.

2 - Quanto mais horas de estudo, maior a nota na prova.

Causalidade, ainda que dependa de outros fatores como qualidade do estudo e do sono também.

3 - Uso de óculos aumenta com o nível de escolaridade.

Correlação. A idade pode ser a “variável escondida”.

ESTUDO DE CASO

4 - Número de ciclistas e acidentes de bicicleta crescem juntos.

Correlação. Mais ciclistas implica mais exposição ao risco.

5 - Quanto mais policiamento em um bairro, maior o número de crimes registrados.

Correlação. O policiamento responde ao crime, não o causa.

6 - Crianças que leem mais têm melhor vocabulário.

Causalidade, embora o ambiente familiar também influencie.

7 - Pessoas que dormem menos usam mais café.

Correlação. Fatores como rotina de trabalho e estresse causam ambos.

ESTUDO DE CASO

8 - Cidades com mais hospitais têm mais mortes registradas.

Correlação. O tamanho da população é a variável escondida.

9 - Alunos que participam de aulas de reforço melhoram as notas.

Causalidade. Embora fatores como motivação e apoio familiar influenciem.

10 - Quanto mais pessoas usam redes sociais, maior o número de diagnósticos de ansiedade.

Correlação. Pode haver influência mútua, mas é difícil estabelecer uma relação de causa, outros fatores estão envolvidos.